ALMA MATER STUDIORUM - UNIVERSITA' DI BOLOGNA

Possono i Large Language Models interpretare opere d'arte sconosciute?

Tesi di laurea in informatica

presentato da:
Thomas Bernardi

Relatore::
Prof. Andrea Asperti

Obiettivo della ricerca

È sempre più comune l’uso dei LLMs per rispondere a domande e supportare attività di analisi in contesti eterogenei.

Tuttavia la loro affidabilità in ambiti complessi è ancora oggetto di studio, uno di questi è il dominio dell’arte.

Il nostro studio analizza il comportamento di 3 LLMs (Gemini, ChatGPT, Claude) nell’arte visiva. Gli obiettivi principali sono:

- valutare l’accuratezza nell’identificazione dell’autore
- far valutare le opere solo visivamente escludendo le conoscenze pregresse
- analizzare le descrizioni generate, secondo criteri formali e storico-artistici

Lavori correlati

GalleryGPT :

Studio sull'uso dei LLM per descrivere l'arte. Ha evidenziato il limite "recognize-then-analyze", il modello si affida alla memoria e non all'osservazione. Propongono il loro modello con prestazioni migliori.

ArtQuest :

Dataset di riferimento per la Visual Question Answering in ambito artistico. Fornisce metadati strutturati (artista, tecnica, genere, scuola, periodo) essenziali per ridurre i bias linguistici nell'analisi.

WAGA Dataset :

Wölfflin Affective Generative Analysis contiene 1.000 opere con annotazioni umane su scala Likert(1-5) per i principi di Wölfflin, usato come ground truth per valutare i modelli.

Principi di Wölfflin :

5 coppie concettuali create dallo storico dell'arte Henrich Wölfflin che permettono un'analisi formale oggettiva dello stile pittorico (Lineare vs Pittorico, superficie vs profondità, forma chiusa vs forma aperta, Molteplicità vs unità, Chiarezza assoluta vs chiarezza relativa).

Dataset Utilizzati

WikiArt

176.000+ opere iniziali
dopo le prime esclusioni:

67.853
opere per il primo prompt

Effettuato il primo prompt
e applicati il filtraggio di
genere e stile:

52.951
opere per il secondo
prompt

ArtQuest

Derivato da SemArt preso
dalla sezione di train con le
dovute esclusioni:

18.293
opere per il primo prompt

Effettuato il primo prompt
e applicati il filtraggio di
genere e tecnica:

13.461
opere per il secondo
prompt

WAGA

1800 opere iniziali con 5
annotazioni per ogni principio
di Wolfflin:

1000
opere reali utilizzate

Non avendo una ground
truth sugli artisti sono state
utilizzate solo per il
secondo prompt
principalmente per avere
una valutazione sui 5
principi di wolfflin

Nota Metodologica: Escluse opere 3D, sculture, architettura e fotografia per focalizzarsi sulla pittura bidimensionale.

Metodologia: pipeline a due prompt

Prompt 1: Fase di riconoscimento

Input: immagine del dataset

↓

Prompt: “Riconosci quest’opera? Si, dimmi l’autore”

↓

Confronto tra artista predetto e reale (token o fuzzy)

↓

Riconosciuta?

Sì	NO / ERRORE
Scartata	Prosegui

Prompt 2: Fase di analisi

Opere non riconosciute + riconosciute con artista errato

Prompt: “Sei un critico d’arte. Analizza attentamente l’opera d’arte fornita. Rispondi solo in formato JSON.” Seguendo questi insiemi chiusi.

Top-3 possibili autori (open)

Macro-stile (24 categorie)

Tecnica (8 categorie)

Genere (10 categorie)

Scuola e periodo storico (26 categorie) (751-800 1851-1900)

Principi Wolfflin (scala 1-5)

Fornisci una breve descrizione (MAX 80 parole)

Esempio primo prompt

Opera analizzata

Opera file:
102839-frank-w-benson-river-scene-1921.jpg

Artista reale:
Frank W. Benson

Risposta Gemini:
Artista predetto: John Henry Twachtman
Titolo predetto: Stream in Summer, Greenwich

Output completo:
```json {  "identified": true,
"artist_name": "John Henry Twachtman",
"artwork_title": "Stream in Summer,
Greenwich" } ```
```

Risultati: primo prompt

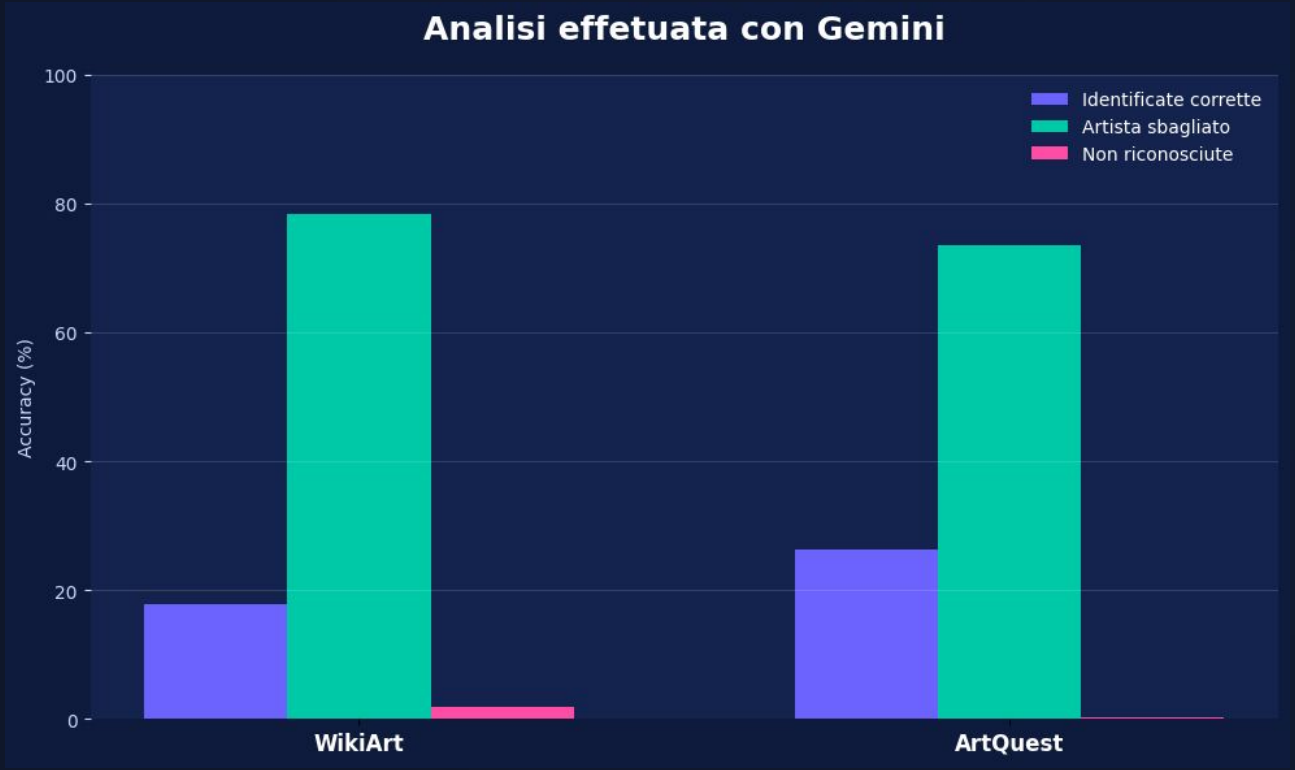

Risultati per WikiArt:
Su 67.853 opere analizzate abbiamo i seguenti risultati: Le non identificate sono l'1.89%, le identificate corrette sono il 17.82% mentre le "identificate" ma sbagliando l'autore sono il 78.31%

Risultati per ArtQuest:
Su 18.293 opere analizzate abbiamo i seguenti risultati: Le non identificate sono lo 0.19%, le identificate corrette sono 26.21%, mentre le "identificate" ma sbagliando l'autore sono il 73.60%

Possiamo notare come il modello tende a dare una risposta anche quando non conosce l'opera, sbagliando l'autore

Esempio secondo prompt

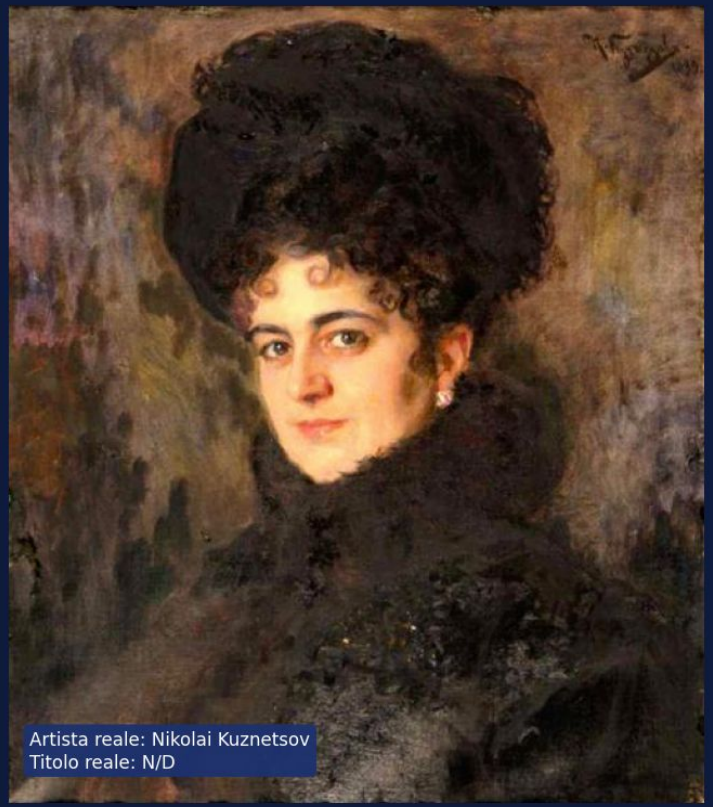

Artista reale: Nikolai Kuznetsov
Titolo reale: N/D

GEMINI

Top 1: Ignacio Zuloaga y Zabaleta
Top 2: Ramón Casas i Carbó
Top 3: Joaquín Sorolla y Bastida

Genere: portrait
Stile: Naturalism / Luminism / Tonalism
Tecnica: oil
Scuola: spanish

Periodo: 1851-1900

Wölfflin:
L/P: 4
P/R: 4
C/O: 2
M/U: 5
A/R: 4

Descrizione:
A three-quarter length portrait depicts a woman...

GPT

Top 1: Giovanni Boldini
Top 2: John Singer Sargent
Top 3: Anders Zorn

Genere: portrait
Stile: Realism
Tecnica: oil
Scuola: italian

Periodo: 1851-1900

Wölfflin:
L/P: 3
P/R: 4
C/O: 3
M/U: 3
A/R: 3

Descrizione:
A finely detailed oil portrait of a woman with...

CLAUDE

Top 1: Ilya Repin
Top 2: Valentin Serov
Top 3: Ivan Kramskoi

Genere: portrait
Stile: Realism
Tecnica: oil
Scuola: russian

Periodo: 1851-1900

Wölfflin:
L/P: 4
P/R: 3
C/O: 2
M/U: 4
A/R: 4

Descrizione:
Portrait of a young woman with dark, voluminous hair...

Risultati: Identificazione artista

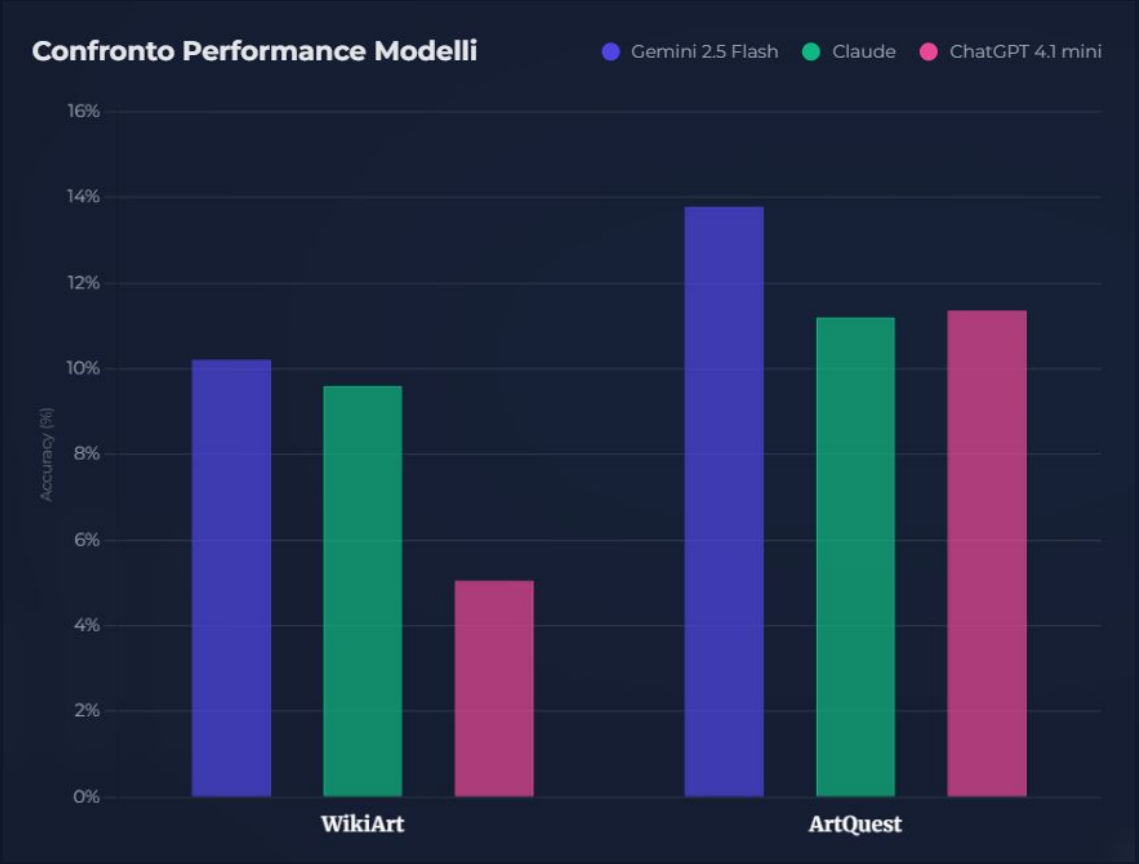

Compito più difficile:

L'identificazione dell'artista su opere meno conosciute risulta il compito più difficile. Mostra infatti le performance più basse in assoluto (max 13%). Non aiutano le 3 possibilità.

Problema delle "hallucination":

I modelli tendono a inventare un autore plausibile (coerente per stile/epoca) piuttosto che ammettere di non riconoscere l'opera.

Prestazioni dei 3 modelli:

Come possiamo notare Gemini mostra le prestazioni migliori. Mentre soprattutto per WikiArt ChatGPT risulta il peggiore (accuratezza 5%).

Risultati: tecnica e genere

Tecnica: performance eccellenti

Presentano un'accuratezza maggiore del 90%, Il migliore è ChatGPT con 94.09%. Le tecniche più riconosciute sono "oil", "fresco" e "aquarell" perchè facilmente riconoscibili e sono anche le più presenti nel dataset.

Genere: performance per WikiArt

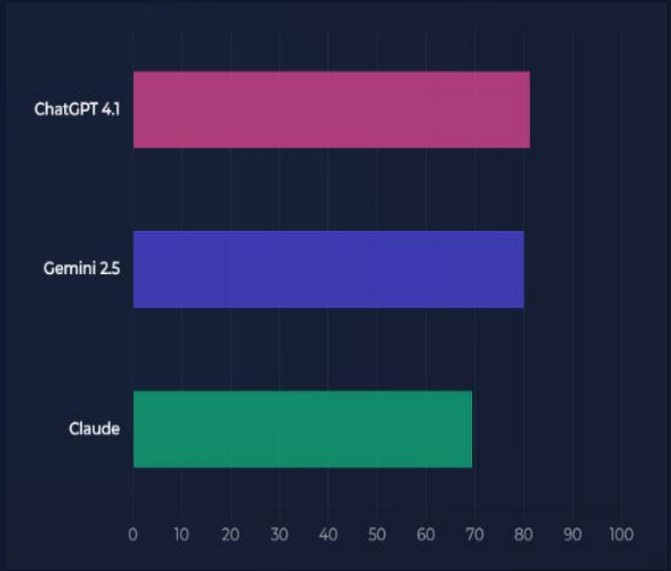

Presentano un'accuratezza del circa 80% (tranne claude che si ferma al 69,35%). Anche per ArtQuest si hanno valori simili (dal 75% all'82%). I generi più riconosciuti sono "landscape", "still-life" quelli più difficili "sketch and study" e "historical"(per Claude).

Risultati: Stile,scuola e periodo

Macro-Stile
(24 categorie)

50.4%
(Max Accuracy)

Valutati per il dataset WikiArt. Prestazioni migliori per Gemini mentre il peggiore è Claude (44%). Gli stili più riconosciuti sono “Asian Traditional” e “Renaissance”, mentre i meno riconosciuti sono “modernism” e “Naive/Outsider”.

Scuola
Geografica
(26 categorie)

66.7%
(Max Accuracy)

Valutate per il dataset ArtQuest. Gemini è il migliore infatti è superiore a ChatGPT +5%, Claude rimane il peggiore (56.17%). Le scuole più riconosciute sono “Italian”, ”english” e “dutch” mentre i peggiori “swiss”, ”hungarian”.

Periodo
Storico
(insiemi ogni 50 anni)

~56%
(Max Accuracy)

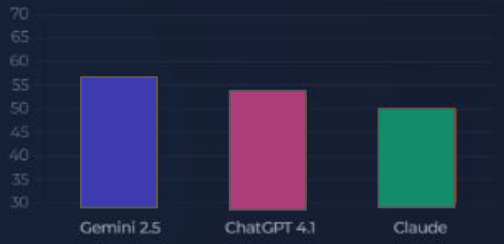

Valutati per il dataset ArtQuest. Anche in questo caso Gemini risulta il migliore, ChatGPT è intermedio (53%) mentre Claude è ancora una volta il peggiore (50%). Le opere pre 1200 non vengono quasi mai riconosciute.

Risultati: prinicipi di wolfflin (WAGA)

Near Accuracy (+/- 1)

Claude supera nettamente gli altri 2 modelli, mostrando una comprensione migliore delle categorie estetiche astratte

LLM	MAE (Error)
Claude	1.00
ChatGPT	1.15
Gemini	1.27

Principio più riconosciuto:

Forma chiusa vs Forma aperta: accuracy 74.9% MAE = 0.77 (per Claude). L'AI distingue bene la composizione strutturata vs libera.

Principio meno riconosciuto:

Chiarezza assoluta vs relativa: accuracy 50.30% MAE = 1.49 (per Gemini). Concetto troppo astratto per i modelli.

Confronto tra i modelli

Gemini
versione 2.5 flash

Migliore per il Top-3 artisti:
Risulta il modello migliore nel predire l'artista corretto sia per WikiArt (10.2%) che ArtQuest (13.79%), seppur rimane bassa in assoluto.

Stile, scuola e periodo:
Ha le prestazioni migliori per lo stile (50.4%) , la scuola geografica (66,7%) e per il periodo storico (56%).

ChatGPT
GPT-4.1 mini

Migliore per la tecnica:
Per quanto tutti modelli presentano le accuratezze più elevate, ChatGPT risulta il migliore nella predizione della tecnica (94.09%).

Migliore per il genere:
Presenta le prestazioni migliori per riconoscere il genere in WikiArt (81.20%) e anche per ArtQuest i risultati sono elevati (76%).

Claude
Haiku-4.5

Analisi Formale:
Risulta il migliore nel predire i principi di Wolfflin ha infatti i valori che si avvicinano di più alla ground truth (near accuracy media 63.7%)

MAE medio più basso:
Presenta l'errore medio più basso rispetto agli altri 2 modelli, indicando una comprensione estetica migliore.

Conclusioni

Analizzando i risultati possiamo affermare che i modelli hanno parecchie difficoltà nel riconoscere l'artista in opere d'arte meno conosciute. Con un'accuratezza del 17% (WikiArt) e 26% (ArtQuest) per il primo prompt, e anche mettendo 3 predizioni possibili, i risultati migliorano del 10% e 13% usando Gemini, mentre gli altri modelli hanno un'accuratezza inferiore.

I risultati migliori li osserviamo nel riconoscere attributi concreti e descrittivi (tecnica e genere), e anche quando non riconoscono l'opera deducono il contesto stilistico e il periodo circa una volta su due.

Infine è stato reso pubblico su GitHub il dataset con immagini e predizioni svolti in questo lavoro per possibili studi futuri:
"https://github.com/thomasbernaardi00/Tesi_Bernardi_Notebook_Dataset"